



**PUC**  
**CAMPINAS**  
PONTIFÍCIA UNIVERSIDADE CATÓLICA

# [12517] **Arquitetura de Grandes Volumes de Dados**

Projeto Final (Parte B)

Prof. Alexandre Seidy Ioshisaqui

2026

# Roteiro

## 1 Atividade e requisitos

- Carregamento e verificação de dados
- Execução da rotina de PCA
- Camada de Apresentação

## 2 Avaliação da atividade

# Projeto Final (Parte B)

## Seção atual

### 1 Atividade e requisitos

- Carregamento e verificação de dados
- Execução da rotina de PCA
- Camada de Apresentação

### 2 Avaliação da atividade

## Experimentando as ferramentas de aprendizado de máquina do Spark

- Este projeto consiste em realizar Análise de Componentes Principais sobre um conjunto de dados reais.
- O foco desta atividade é a familiarização com as ferramentas de aprendizado de máquina do Spark.
- Códigos auxiliares foram fornecidos no `.ipynb`.

## Partes da atividade

- 1 Carregamento e verificação de dados
- 2 Execução da rotina de PCA
- 3 Análise baseada nas matrizes de pesos e de pontuações

## Subseção atual

### 1 Atividade e requisitos

- Carregamento e verificação de dados
- Execução da rotina de PCA
- Camada de Apresentação

## 1. Carregamento e verificação de dados

- Utilizaremos dados fornecidos pelo Instituto Nacional de Meteorologia (INMET).
- <https://portal.inmet.gov.br/dadoshistoricos>
- Cada grupo deverá escolher um ano entre 2010 e 2024 (sem repetição).
- Seguindo o código de referência, carreguem e verifiquem se os dados estão apropriados para a realização dos cálculos.
- Realizem os devidos tratamentos e documentem estas decisões.

## Subseção atual

### 1 Atividade e requisitos

- Carregamento e verificação de dados
- Execução da rotina de PCA
- Camada de Apresentação

## 2. Execução da rotina de PCA

- Com os dados já tratados, execute a rotina de PCA utilizando as funções do Spark.
- Os dados precisarão ser tratados com as rotinas `VectorAssembler` e `StandardScaler` do Spark.
- Sigam o código-exemplo no `.ipynb`.

## Subseção atual

### 1 Atividade e requisitos

- Carregamento e verificação de dados
- Execução da rotina de PCA
- Camada de Apresentação

### 3. Camada de Apresentação

- Sendo  $T = XW$  o resultado da decomposição matricial efetuada pelo PCA, onde:
  - $X$  é a matriz dos dados (coordenadas originais);
  - $T$  é a matriz de pontuação dos dados (novas coordenadas) e;
  - $W$  é a matriz das componentes principais.
- Realize algum tipo de visualização dos dados de  $T$ 
  - Pode ser uma amostra reduzida
  - Para amostragem, utilizem: `sdf.sample(fraction=0.1)`, onde `fraction` é um valor que varia de 0.0 (0%) a 1.0 (100%).
- Realize e apresente algum tipo de análise interpretativa sobre os vetores de  $W$ .

## Seção atual

1 Atividade e requisitos

2 Avaliação da atividade

# Avaliação da atividade

## Notas

- Média da parte prática:
  - $0.4 \times$  Média das Atividades Práticas
  - $0.3 \times$  Projeto Final (Parte A)
  - $0.3 \times$  Projeto Final (Parte B)

## Datas

- 07/maio: Início do Projeto Final (Partes A e B)
- 11/junho: Prazo final de entregas (Partes A e B)
- 18/junho: Prazo final de apresentações (Partes A e B)

### (1/2) Implementação (4 pts.)

- (2 pts.) Funcionalidade
- (2 pts.) Documentação e organização da implementação

## (2/2) Apresentação (6 pts.)

- (2 pts.) Carregamento e verificação de dados
- (2 pts.) Execução da rotina de PCA
- (2 pts.) Análise baseada nas matrizes de pesos e de pontuações